

O mercado brasileiro de dados, em três edições da mesma pesquisa

Tech Challenge Fase 3 · Engenharia de Dados e Analytics em ambiente AWS

Ana Paula Corrêa Galdino · RM370461

POSTECH, Data Analytics (DTAT)

Setembro de 2026

A IA virou prioridade, o talento sênior encareceu e a diversidade regrediu

60,6%

dos respondentes dizem que a empresa prioriza IA generativa

Eram 36,2% duas edições atrás. Só 26,5% declaram projetos em produção gerando resultado.

+40%

na faixa salarial mediana do profissional Sênior

Júnior e Pleno ficaram parados nas três edições. Contratar pronto encareceu, formar não.

22,0%

de participação feminina, em queda nas duas transições da série

Eram 24,4% na primeira edição. A direção é a mesma nas três, não é oscilação de amostra.

39,7%

em trabalho totalmente remoto, contra 46,3% antes

Os dois modelos flexíveis pagam R\$ 14.000 de mediana, contra R\$ 7.000 no presencial integral.

A decisão do cliente depende de evidência que ele não tem

SITUAÇÃO

Expandir a área de dados e IA

Uma instituição financeira de grande porte precisa definir contratação, capacitação e investimento em tecnologia.

COMPLICAÇÃO

Faltam evidências sobre o mercado

Salário, senioridade, stack e modelo de trabalho mudam rápido, e a percepção interna não acompanha.

RESOLUÇÃO

Três edições da mesma pesquisa

14.005 respostas do State of Data Brazil, processadas em um data lake na AWS e lidas como série histórica.

Todas as análises deste material respondem a uma dessas três decisões, e nenhuma recomendação aparece sem o número que a sustenta.

Três edições, mais de mil perguntas, uma base que não se une sozinha

14.005

respostas nas três
edições da pesquisa

1.190

colunas somadas
entre as edições

3

padrões diferentes de
nomenclatura de coluna

145

códigos que mudam de
significado entre edições

Edições utilizadas: 2023-2024, 2024-2025 e 2025-2026, as três últimas publicadas pelo Data Hackers, conforme exige o enunciado.

Após o tratamento restam 14.002 linhas: três registros eram duplicatas integralmente idênticas e foram removidos.

Nenhum arquivo foi aberto ou salvo em planilha antes da ingestão, para preservar codificação, separador e formato de origem na camada Bronze.

Um data lake em camadas, com todo o processamento em Spark



O código da pergunta muda de significado entre as edições

O mesmo código 2.q, em três edições

2023-2024 ocorrência de demissões em massa

2024-2025 ocorrência de demissões em massa

2025-2026 **modelo de trabalho atual**

Unir as bases pelo código produziria um gráfico comparando demissões com trabalho remoto, sem gerar erro algum na execução.

A regra adotada: tripla confirmação

- código da pergunta
- texto integral da pergunta
- categorias observadas nos dados

Só entra na série histórica a coluna aprovada nos três critérios. O mapa completo das 237 perguntas equivalentes acompanha a entrega.

330

códigos existem nas três edições

145

deles mudam de pergunta


237

perguntas são equivalentes

92

delas trocaram de código

Finanças e tecnologia concentram mais de um terço do mercado




Onde estão os profissionais

Os dois maiores setores somam 36,0% dos respondentes. A diferença entre eles, de 1,1 ponto, não é significativa a 95% de confiança: é empate na liderança.

O que isso significa

O cliente disputa talento em um dos dois maiores empregadores de dados do país, contra concorrentes diretos e contra empresas de tecnologia.

A concentração no Sudeste aumentou em vez de ceder ao trabalho remoto




Concentração crescente

O Sudeste sai de 61,4% para 64,4% entre a primeira e a última edição, sem qualquer sinal de dispersão geográfica.

Leitura para contratação

Buscar talento fora do eixo tradicional continua sendo exceção, e não a regra do mercado.

A faixa mediana do Sênior subiu 40% e as de entrada não se moveram



O que mudou

O Sênior saiu de R\$ 10.000 para R\$ 14.000 entre a primeira e a segunda edição e estabilizou. Júnior e Pleno não se moveram.


A decisão que isso força

O preço de entrada da senioridade subiu 40% e o do Pleno não subiu. Formar internamente ficou relativamente mais barato do que disputar Sênior pronto.

O topo novo

A edição 2025-2026 criou o nível Especialista/Staff+, com mediana de R\$ 18.000 sobre 349 respostas. Por existir em uma só edição, ele fica fora da série histórica.

Engenharia de dados e machine learning lideram a mediana salarial



Quem o mercado paga melhor

ML e AI Engineer lidera com mediana de R\$ 18.000. Engenharia e Arquitetura de Dados, Analytics Engineer e Data Product Manager vêm em seguida, todos em R\$ 14.000.


A distância dentro da área

Analista de Dados, de BI e de Negócios ficam em R\$ 7.000, metade da mediana dos cargos de engenharia. O rótulo genérico de profissional de dados esconde uma diferença de duas vezes.

Leitura para o cliente

Se a expansão prevê plataforma e IA, o orçamento por posição parte de R\$ 14.000. Se prevê consumo analítico, parte de R\$ 7.000.

A participação feminina cai edição após edição, de 24,4% para 22,0%




Tendência, não ruído

São 2,5 pontos perdidos nas duas transições da série, sempre na mesma direção, sobre bases de 5.293, 5.215 e 3.494 respostas.

Risco para o cliente

Uma base que encolhe reduz o alcance de qualquer meta de diversidade construída sobre contratação externa.

Proporcionalmente, mais mulheres na entrada e menos no topo




O funil aperta na senioridade

Entre as mulheres, 25,8% estão no nível Júnior, contra 19,1% entre os homens. No Sênior a relação se inverte, 31,4% contra 35,2%.

Onde agir

O gargalo está na progressão, não apenas na porta de entrada. Programas de promoção interna atacam a causa certa.

Python domina e o SQL aparece ao lado dele, não no lugar





Stack estável

Python é a linguagem preferida de forma dominante nas três edições, sem concorrente próximo.

Mudança de formato

Em 2025-2026 a pergunta passou a aceitar mais de uma resposta, por isso a métrica é a menção e a soma ultrapassa 100% naquela edição.

AWS lidera na nuvem e o Power BI não tem concorrente em BI



Nuvem

AWS é a preferida de 31,7% dos respondentes que declaram preferência, à frente de Google Cloud, com 20,6%, e Azure, com 14,7%.


Visualização

Power BI concentra 50,5% da preferência declarada, cinco vezes o segundo colocado. Nenhuma outra ferramenta passa de 10%.

Consequência para o cliente

A solução deste projeto foi construída em AWS, a mesma nuvem em que o mercado tem mais gente pronta para contratar.

A adoção de IA quase dobrou enquanto a rejeição caiu pela metade




A maior mudança do período

A IA generativa passou de prioridade declarada por 36,2% dos respondentes para 60,6% em duas edições. Nenhum outro indicador se moveu tanto.

A janela está aberta agora

Quem estrutura a área de IA neste ciclo entra junto com o mercado. Quem esperar mais uma edição entra atrasado.

Em duas edições, a IA saiu da margem e virou pauta de orçamento




O detalhe da mudança

O crescimento vem das duas faixas de prioridade declarada, com discussão de orçamento, e não de uso informal.

Quem ficou para trás

Apenas 11,4% dos respondentes dizem que a IA não é prioridade na empresa, contra 28,8% duas edições atrás.

A prioridade já virou consenso, o resultado em produção ainda não



O tamanho da lacuna

Enquanto 60,6% declaram a IA como prioridade, apenas 26,5% dizem ter projetos em produção gerando resultado no negócio.


Onde o mercado está parado

38,4% mantêm pilotos rodando sem impacto declarado. Somados aos 15,0% em planejamento, mais da metade ainda não saiu da experimentação.

A oportunidade

A disputa deixou de ser por adotar IA e passou a ser por operacionalizar. Quem tira o piloto do papel primeiro captura o diferencial.

O trabalho remoto recua e o presencial avança




Movimento recente

O remoto integral caiu 6,6 pontos e o presencial integral subiu 4,1, concentrados na última edição.

Contramão da preferência

O modelo que mais encolhe está entre os dois de maior satisfação declarada, empatados no topo, como mostra o gráfico seguinte.

Flexibilidade, e não o remoto puro, separa satisfeitos de insatisfeitos



O que os dados dizem

Remoto integral e híbrido flexível empatam no topo, com 74,5% e 75,0%. A diferença de 0,5 ponto não é significativa a 95%, com z igual a 0,23.

Onde está a diferença real

A separação está entre ter e não ter flexibilidade: 20,9 pontos entre o híbrido flexível, com 75,0%, e o presencial integral, com 54,0%.

Consequência prática

Política de trabalho deixa de ser assunto administrativo e passa a ser instrumento de retenção de talento escasso.

Três decisões que os dados sustentam

CONTRATAR

Contratar no meio da carreira e promover por dentro

A faixa mediana do Sênior subiu 40% em duas edições e a do Pleno não se moveu. O prêmio pago por senioridade pronta cresceu, o custo de quem ainda vai chegar lá não, e a disputa acontece em um dos dois maiores empregadores de dados do país.

CAPACITAR

Tratar IA generativa como competência de todo o time

Seis em cada dez respondentes dizem que a empresa já priorizou IA, mas só 26,5% declaram projetos em produção gerando resultado. A vantagem competitiva não está mais em adotar, e sim em sair do piloto, o que depende de gente treinada dentro de casa.

INVESTIR

Usar flexibilidade de trabalho como instrumento de retenção

Os dois modelos flexíveis pagam mediana de R\$ 14.000, contra R\$ 7.000 no presencial integral, e concentram a maior satisfação declarada. Com o remoto encolhendo 6,6 pontos no mercado, manter flexibilidade é alavanca de retenção e de custo ao mesmo tempo.

O que sustenta os números, e o que eles não podem dizer

Como os números foram apurados

- Arquivos originais preservados na camada Bronze, sem tratamento prévio
- Colunas confirmadas por código, texto da pergunta e categorias observadas
- Erros de digitação da pesquisa de origem corrigidos e documentados
- Indicadores principais recalculados por caminho independente
- Diferenças entre categorias testadas antes de virarem afirmação

O que os dados não permitem afirmar

- A pesquisa é voluntária: descreve a comunidade respondente, não o país
- A remuneração é coletada em faixas, então não existe salário médio aqui
- Os valores são nominais: a variação não desconta a inflação do período
- As perguntas sobre IA são respondidas só por quem trabalha em empresa, com base menor
- A última edição tem menos respondentes, por isso toda comparação é percentual
- Perguntas de uma só edição não entram em série histórica
- O nível Especialista/Staff+ existe apenas na edição mais recente

Todo o código, os notebooks executados e as consultas SQL acompanham a entrega e reproduzem estes números do zero.

Repositório público com todo o material: github.com/AnaPaula-Galdino/tech-challenge-fase3-state-of-data

Obrigada

O mercado brasileiro de dados está mais caro no topo, mais concentrado do que parece e mais decidido sobre IA do que estava há dois anos. As três decisões deste material saem daí.

Todo o material, código, notebooks e documentação: github.com/AnaPaula-Galdino/tech-challenge-fase3-state-of-data

Ana Paula Corrêa Galdino · RM370461 · POSTECH Data Analytics